

Здравствуйте!

Хочу откликнуться на вакансию Senior / Lead LLM Engineer (Python).

Мне близок ваш формат builder first: проектировать, сразу писать код и быстро доводить фичи до продакшена. Последний год в основном этим и занимаюсь — LLM-цепочки, RAG-подобный retrieval, асинхронные воркеры, production-надёжность.

Сейчас — Staff Engineer на AI SaaS (стартап): многостадийная обработка (STT → embeddings/retrieval → LLM), Pub/Sub, статусы в API. Закрывал реальные прод-проблемы: latency, стоимость токенов, нестабильные ответы моделей, partial failures в цепочках. До этого — Qantev (LLM/ML по документам, FastAPI, async inference) и Oscar Health (микросервисы, high-load).

Стек: Python, FastAPI, asyncio, RAG/retrieval, embeddings, event-driven, microservices, GCP. С LangChain/LangGraph в бою пока меньше, чем с собственными пайплайнами, но экосистему знаю и быстро встраиваюсь — паттерны те же: chains, state, retries, eval.

Match (в резюме): 6+ лет Python · LLM in prod · RAG · FastAPI/asyncio · microservices · startup pace · remote · English B2.

Буду рад коротко пройти по одному production AI-пайплайну на созвоне.

С уважением,
Максим Василенка
Минск, Беларусь